

HW3: 深度強化學習 (DQN) 實驗與效能分析報告

1. 實驗目標

本實驗旨在透過 Gridworld 環境，實作並比較各種 DQN 演算法及其變體。實驗從基礎的 Naive DQN 開始，逐步引入 Double DQN、Dueling DQN，最終轉換為 PyTorch Lightning 框架並實作 Full Rainbow DQN，以解決高度隨機化的 Random Mode 環境。

2. HW3-1: Naive DQN 與 Experience Replay 基礎

2.1 核心機制理解

- **Experience Replay (經驗回放):**
 - 目的: 打破訓練資料的時間相關性 (Temporal Correlation)。
 - 作用: 將 (s, a, r, s') 存入 Buffer，隨機抽樣進行批次訓練，提高資料利用率並增加訓練穩定度。
- **Target Network (目標網路):**
 - 固定目標值 Y ，避免訓練時目標值隨參數更新劇烈變動，解決「追逐自己影子」的不穩定問題。

2.2 靜態模式觀察

在靜態模式下，環境固定，DQN 很快就能學會「背地圖」。此階段驗證了 DQN 基本架構的正確性。

3. HW3-2: 強化學習變體比較 (Double vs. Dueling)

本階段將實驗環境升級至較具挑戰性的規模，以量化不同 DQN 改良方案的效能差異。

3.1 實驗參數設定

- 地圖大小 (Grid Size): 8×8 。相較於 4×4 ，狀態空間維度由 64 暴增至 256 ($4 \times 8 \times 8$)。
- 模式 (Mode): player 模式。環境物件固定，僅玩家起始位置隨機，測試模型對大範圍空間路徑的規劃能力。
- 訓練長度 (Epochs): 1500。在 256 維度的輸入空間下，1500 次迭代足以觀察到各演算法收斂曲線的分歧點。


3.2 技術原理與觀測

- **Double DQN:** 有效抑制了基礎 DQN 在 8×8 大地圖中容易產生的「動作價值過度樂觀」現象 (Overestimation Bias)。
- **Dueling DQN:** 在大空間中表現最為卓越。由於地圖變大，許多狀態下的動作優勢 (

Advantage) 差異微小, 透過分離 V 與 A , 模型能更有效地學習哪些「位置」本質上是安全的。

3.3 實驗數據分析

- 數據分析: 使用 **Log Scale** (對數座標) 繪製。圖中規律的尖刺反映了 **Hard Update** (每 500 步同步一次 **Target Network**) 的衝擊。
- 結論: Dueling DQN (綠線) 在 1500 Epochs 的訓練中, Loss 下降最快且最終數值最低。相較之下, Basic DQN (藍線) 收斂效率最差, 證明了變體演算法在複雜環境下的必要性。



4. HW3-3: 隨機模式與 PyTorch Lightning 框架轉換

4.1 Random Mode 的挑戰與環境設定

- 地圖大小 (Grid Size): **4x4**。為了專注於驗證模型在「全隨機生成」環境下的泛化能力, 本階段切換回 4x4 的精簡配置。
- 挑戰: 在 random 模式下, 起點、終點與陷阱位置每局都在變動。模型必須從「背地圖」進化到「理解像素語義」(辨識不同圖層代表的實體意義)。


4.2 穩定訓練技巧 (Bonus Points)

- 穩定性提升: 引入 **Soft Update (Polyak Averaging)** 取代 Hard Update, 使 Loss 曲線告別了 HW3-2 中的尖刺, 呈現極度穩定的下降趨勢。
- 優化配置: 全面導入 PyTorch Lightning 框架, 並搭配 Gradient Clipping 與 LR Scheduler (學

習率排程器)來穩定訓練。

4.3 最終測試結果

訓練完成後，我們在完全隨機的環境下進行了 1000 局的嚴格測試，模型成功克服了隨機模式的挑戰，展現了極高的泛化能力：



Testing model for 1000 games in 'random' mode...

Final Win percentage: 96.00%

5. HW3-4: 終極挑戰 - Full Rainbow DQN (Bonus)

5.1 技術整合分析


Rainbow DQN 整合了六大核心技術 (C51, Noisy Nets, PER, N-step 等)，旨在提供最強大的探索與分佈預測能力，但在小型環境中存在較高的訓練門檻。

5.2 實驗觀察與瓶頸分析

- 低勝率診斷：初期實驗勝率僅 9.3%，診斷出 **NoisyNet** 悲觀龜縮 問題，顯示過小的初始雜訊會導致模型過早放棄探索。
- 優化結果：將 `std_init` 調高至 0.5 強制探索，並將 `replay_size` 擴大至 50,000 後，勝率在 50 萬步時回升至 **66.9%**。
- 極限測試結論：實驗進一步將訓練步數提升至 1,000,000 步，觀測結果顯示最終勝率依然

維持在 66.9%。這代表模型已達到當前超參數下的收斂高原。

- 深度分析：
 1. 過度擬合問題：在 4x4 的環境中，Rainbow 的 51 個分佈支撐點可能因模型過於複雜而產生量化誤差。
 2. 複雜度失衡：Full Rainbow 的高階機制（如分佈式 RL）更適合高維、連續或極度不穩定的環境。在相對簡單的 4x4 Gridworld 中，過多的超參數反而增加了最佳解的搜尋難度。



6. 結論與心得

透過本系列實驗，我深刻體會到「沒有最強的演算法，只有最適合環境的設定」。

- 大型靜態環境 (8x8 Player): Dueling DQN 是兼顧速度與準確度的首選。
- 全隨機環境 (Random Mode): 穩定性技巧 (Soft Update) 與訓練框架 (Lightning) 對於防止模型崩潰至關重要。
- 技術廣度: 實作 Full Rainbow DQN 雖然在 4x4 環境下受限於模型複雜度，其勝率 (66.9%) 未能超越精簡版 Dueling DQN (96%)，但其對獎勵分佈的捕捉能力與 PER 的優先學習機制，是未來處理大範圍真實世界任務的關鍵技術儲備。